

Diseño e Implementación de un Framework de Big Data Analytics sobre Reseñas de Restaurantes en el Perú basado en Datos de Google Maps

Fabrizio Marin

Departamento de Ingeniería
Universidad del Pacífico
Lima, Perú
sf.marinc@alum.up.edu.pe

Bruno Herrera

Departamento de Ingeniería
Universidad del Pacífico
Lima, Perú
ba.herrerc@alum.up.edu.pe

Marx Rojas

Departamento de Ingeniería
Universidad del Pacífico
Lima, Perú
lm.rojasro@alum.up.edu.pe

Tadashi Vigo

Departamento de Ingeniería
Universidad del Pacífico
Lima, Perú
dt.vigop@alum.up.edu.pe

Mario Auqui

Departamento de Ingeniería
Universidad del Pacífico
Lima, Perú
mm.auquic@alum.up.edu.pe

Resumen—El análisis nacional de la experiencia gastronómica exige procesar volúmenes históricos y flujos continuos de reseñas que superan los enfoques de un solo nodo. Este trabajo diseña e implementa un framework de Big Data escalable para recolectar, integrar y analizar reseñas públicas de restaurantes visibles en Google Maps. La solución se implementa en Databricks y adopta una arquitectura Lambda con metodología medallón sobre Spark y Delta Lake, mientras que la capa de velocidad incorpora nuevas reseñas mediante Kafka y Spark Structured Streaming. Con ello, la limpieza, deduplicación, agregación, análisis espacial y modelamiento no supervisado se ejecutan de forma distribuida, favoreciendo reproducibilidad y escalamiento horizontal. El corpus integra 3.43 millones de reseñas sobre 39 947 establecimientos y, tras la depuración, conserva 2.78 millones de registros únicos aportados por 1.2 millones de usuarios. Los resultados muestran concentración de actividad en Lima Metropolitana, sesgo hacia calificaciones positivas y reseñas negativas más informativas. La segmentación con Spark MLlib identifica siete perfiles de revisores, desde promotores satisfechos hasta críticos detallistas, y el modelado de tópicos resume cinco dimensiones de la experiencia asociadas a servicio, comida, ambiente, recomendación e insatisfacción operativa. Se concluye que el enfoque distribuido permite transformar reseñas públicas dispersas en una base analítica reutilizable para monitoreo reputacional, inteligencia competitiva y decisiones sectoriales, interpretando los hallazgos como evidencia del mercado visible en Google Maps y no como un censo gastronómico.

Index Terms—analítica de datos masivos, arquitectura Lambda, procesamiento distribuido, minería de opiniones, segmentación de usuarios

I. INTRODUCCIÓN

En el Perú la gastronomía es, al mismo tiempo, industria e identidad nacional. Tras el *boom* gastronómico de la primera década del presente siglo, el país se posicionó entre los destinos culinarios más reconocidos del mundo. Según una nota periodística que recoge declaraciones del MINCETUR, el sector llegó a contar con más de 220 000 establecimientos

gastronómicos a nivel nacional y se asociaba con cerca del 11.2 % del PBI [1]. No obstante, este crecimiento sin parangón trajo consigo el desarrollo de un mercado altamente informal, fragmentado y competitivo, donde la diferenciación ya no se sostiene únicamente en la propuesta culinaria, sino también en la calidad de la experiencia del cliente.

Medir dicha experiencia de manera sistemática es costoso. Las herramientas convencionales como las encuestas de NPS transaccional, el *mystery shopping* y las auditorías de servicio quedan solo al alcance de cadenas respaldadas por importantes líneas presupuestales de las que la microempresa gastronómica carece. Esta última, sin embargo, representa a la mayoría del tejido empresarial del sector.

Este vacío metodológico coexiste, paradójicamente, con una fuente de retroalimentación pública y muy económica: las reseñas en Google Maps. Allí, cualquier comensal puede dejar una valoración en formato de puntaje o texto, visible para millones de usuarios, convirtiendo a esta plataforma en uno de los repositorios gastronómicos de Contenido Generado por Usuario (UGC, por sus siglas en inglés) más grandes del país. Con todo, esta fuente permanece sistemáticamente desaprovechada, pues la mayoría de los establecimientos no cuenta con procesos para monitorear ni interpretar este flujo continuo de retroalimentación, y los organismos rectores del sector tampoco explotan su dimensión agregada.

A nivel individual, gestionar decenas de reseñas puede resultar viable manualmente, pero una analítica integral de la industria a nivel nacional rebasa cualquier capacidad convencional: el corpus supera los tres millones de documentos y crece de forma continua. Este doble requerimiento —volumen histórico masivo y un flujo entrante incesante— es precisamente el que motiva una solución de *Big Data*. La literatura sobre *opinion mining* ha demostrado que el texto corto no estructurado de las reseñas contiene señales consistentes sobre atributos de

servicio como atención, tiempo de espera y relación calidad-precio [2]; extraer esas señales a escala exige procesamiento distribuido y reproducible.

A diferencia de la entrega anterior, en la que el análisis pesado se realizaba en memoria con herramientas de un solo nodo, en esta versión todo el flujo analítico se ejecuta de forma distribuida sobre Apache Spark, integrando además una capa de ingesta en tiempo casi real con Apache Kafka.

El presente trabajo tiene como objetivo general diseñar e implementar un *framework* de Big Data basado en reseñas de Google Maps para caracterizar la estructura territorial, reputacional y temática del mercado gastronómico peruano observable en la plataforma, y evaluar su utilidad como insumo exploratorio para la toma de decisiones. Para ello se articulan los siguientes objetivos específicos, que en conjunto conforman un pipeline distribuido que integra *web scraping*, ingeniería de datos y analítica sobre flujos de procesamiento reproducibles:

- Diseñar e implementar un pipeline de recolección, depuración e integración de reseñas gastronómicas a escala nacional, organizado bajo una arquitectura Lambda y la metodología medallón Bronze/Silver/Gold sobre Spark y Delta Lake.
- Caracterizar la distribución geográfica y temporal de los establecimientos visibles en Google Maps y de la actividad de reseñas, identificando patrones de concentración territorial, visibilidad digital y evolución del comportamiento evaluativo dentro de la plataforma.
- Analizar perfiles de usuarios/revisores a partir de variables de participación, valoración y esfuerzo textual mediante K-Means en Spark MLlib, con el fin de reconocer comportamientos evaluativos diferenciados.
- Identificar tópicos recurrentes en el corpus textual mediante LDA en Spark MLlib, reportando términos dominantes y métricas internas de ajuste que sintetizan dimensiones de la experiencia gastronómica.
- Consolidar una base analítica reutilizable para monitoreo continuo, inteligencia competitiva y futuras aplicaciones de recomendación, apoyada en Kafka y Spark Structured Streaming para la ingesta de nuevas reseñas.

II. REVISIÓN DE LITERATURA

La analítica de macrodatos aplicada a la industria gastronómica ha evolucionado desde enfoques descriptivos basados en reseñas y calificaciones hacia arquitecturas más integradas capaces de transformar el UGC en inteligencia de negocio. En el contexto de los restaurantes, el UGC constituye una fuente clave de evidencia sobre la percepción del cliente, la calidad del servicio y el desempeño operativo. Las calificaciones numéricas y las reseñas textuales funcionan como variables *proxy* de satisfacción, reputación e incluso de desempeño comercial, lo que ha motivado el uso de aprendizaje automático, minería de texto y arquitecturas de datos para capturar su valor analítico.

Diversos estudios abordan la analítica de restaurantes desde perspectivas complementarias. En la adopción digital, se

evidencia que la madurez digital de las empresas gastronómicas se relaciona con mejores capacidades de respuesta y mayor resiliencia operativa [3], [4]. Paralelamente, se han propuesto arquitecturas orientadas al monitoreo continuo del mercado, capaces de integrar múltiples fuentes y proporcionar una visión más amplia del entorno competitivo [5]. Estos trabajos muestran que el valor del dato no se limita al análisis retrospectivo, sino que puede convertirse en soporte para decisiones en tiempo casi real, lo que justifica diseños híbridos *batch/streaming*.

Otra línea se concentra en la dimensión espacial y temporal del desempeño restaurantero. Los modelos espaciales estudian cómo la aglomeración geográfica, la densidad de competencia y la localización influyen en la rentabilidad [6], mientras que los análisis de series temporales muestran que las variaciones en la reputación digital pueden asociarse con cambios en el flujo de clientes [7].

El análisis del comportamiento del consumidor ha incorporado con fuerza el procesamiento de lenguaje natural y el agrupamiento no supervisado. Algunas investigaciones usan *clustering* para segmentar clientes según patrones de interacción [8]; otras aplican minería de texto sobre reseñas para identificar atributos operativos críticos [9], [10]. El modelado de tópicos ha permitido detectar tendencias emergentes en preferencias [11], y los sistemas de recomendación híbridos se han propuesto para mejorar la retención [12].

Desde la perspectiva tecnológica, la presente solución se apoya en componentes consolidados de *Big Data*: Apache Spark como motor unificado de procesamiento distribuido [13], Apache Kafka como sistema de mensajería para flujos [14], Delta Lake como almacenamiento transaccional ACID sobre objetos en la nube [15] y el patrón de arquitectura Lambda para conciliar procesamiento *batch* y de baja latencia [16].

A pesar de estos avances, la literatura presenta limitaciones que justifican la investigación. Muchos estudios dependen de conjuntos estáticos, reducidos o restringidos a una sola plataforma [3], [8]; varios se concentran en una sola dimensión analítica sin integrar variables espaciales, textuales y reputacionales en un mismo flujo [6], [11]; y la mayoría se ubica en contextos anglosajones, dejando poco explorado el caso peruano. Estas brechas muestran la necesidad de un enfoque robusto, escalable e integrado que articule la ingesta masiva de UGC, el procesamiento distribuido y la extracción de conocimiento útil para la toma de decisiones.

III. ARQUITECTURA DEL SISTEMA

El framework se estructura como una **arquitectura Lambda** [16]. Es importante precisar el sentido en que se usa el término: la naturaleza Lambda del sistema proviene de la coexistencia de dos rutas de procesamiento complementarias —una capa **batch**, que procesa el corpus histórico masivo, y una capa de velocidad (**streaming**) basada en **Apache Kafka**, que procesa las reseñas que van llegando— reconciliadas en una capa de servicio común. No es el patrón medallón el que define la arquitectura: el medallón (Bronze/Silver/Gold)

es únicamente el esquema de calidad progresiva de los datos *dentro* de la capa batch. Dicho de otro modo, lo que hace al sistema Lambda es *batch + streaming con Kafka*, no el medallón. La Figura 1 muestra los componentes lógicos y las tecnologías que los implementan.

La Figura 2 complementa la vista general anterior con el detalle lógico del recorrido de los datos. En ella se distinguen las responsabilidades de ingesta, procesamiento histórico, procesamiento de velocidad, reconciliación medallón, modelamiento distribuido y consumo analítico.

III-0a. Capa batch: Procesa el corpus histórico extraído por los *scrapers* aplicando el patrón medallón sobre Delta Lake. La capa *Bronze* preserva el dato crudo tal como se ingesta; la capa *Silver* lo depura, integra reseñas con locales y deriva los atributos de análisis; y la capa *Gold* materializa las vistas analíticas finales. Esta progresión por niveles de calidad garantiza trazabilidad y permite reconstruir cualquier etapa de forma reproducible.

III-0b. Capa de velocidad: Un productor publica las reseñas entrantes en un *topic* de Apache Kafka, desde donde Spark Structured Streaming las consume en micro-lotes, descarta las que ya existen en el histórico y las incorpora a una tabla Bronze de *streaming*. Frente al reprocesamiento completo del histórico, esta vía ofrece baja latencia para los datos recientes.

III-0c. Reconciliación y servicio: Ambas rutas convergen: al regenerar la capa Silver, el histórico y lo recién llegado por el flujo se unifican y deduplican, de modo que las vistas Gold reflejan siempre el estado más actual. La orquestación se realiza mediante *jobs* de Databricks, que disparan el reprocesamiento aguas abajo una vez que el flujo termina de escribir. Sobre las vistas Gold —punto único de consumo— operan los modelos de aprendizaje y las visualizaciones geoespaciales, ya implementados. La exposición de resultados hacia un tablero interactivo y un *endpoint* de servicio constituye la capa de consumo *prevista* en el diseño (Figuras 2 y 10): desacopla el cómputo pesado del consumo por parte de aplicaciones y usuarios de negocio, y se plantea como trabajo de implementación inmediato.

La elección de cada componente responde a los requisitos del problema y no a la mera disponibilidad. **Apache Spark** provee un motor unificado que ejecuta *batch* y *streaming* con la misma interfaz de programación [13], evitando duplicar la lógica de procesamiento; sobre él, *Spark SQL* resuelve la limpieza y las agregaciones, mientras que *Spark Structured Streaming* atiende el flujo entrante. **Delta Lake** aporta transaccionalidad y control de esquema sobre el almacenamiento de objetos en la nube, lo que vuelve seguras las reescrituras del medallón y habilita el reproceso reproducible de las capas Silver y Gold [15]. **Apache Kafka** se eligió como canal de ingesta por ser un *log* distribuido y *duradero*, capaz de retener y reentregar mensajes y de absorber ráfagas mediante control de flujo [14]; un almacén en memoria como Redis, orientado a baja latencia volátil, encajaría como caché del *endpoint* de servicio, pero no como columna vertebral de una ingesta que exige persistencia y reprocesamiento. La **lectura**

Tabla I
DESCRIPCIÓN DE VARIABLES DEL DATASET DE RESTAURANTES

Variable	Descripción
id	Identificador único del local (<i>Place ID</i>)
title	Nombre comercial del restaurante
category	Clasificación del establecimiento
address	Dirección física completa
coor	Coordenadas espaciales (latitud, longitud)
stars	Calificación promedio histórica (1 a 5)
reviews	Volumen total de reseñas recibidas
url_place	Enlace canónico de Google Maps

y **orquestación** se delegan a *jobs* de Databricks, que ejecutan los *notebooks* del flujo (medallón, ingesta y modelamiento) de forma programada o encadenada; Databricks integra además el cómputo Spark gestionado, el gobierno de datos mediante Unity Catalog y el almacenamiento en *Volumes*, reduciendo la fricción operativa de coordinar estos servicios por separado.

IV. MATERIALES Y MÉTODOS

La investigación adopta un diseño computacional y exploratorio en el que el procesamiento y el modelado se ejecutan de forma distribuida sobre Apache Spark. Las bibliotecas de un solo nodo se reservan exclusivamente para graficar resultados ya agregados, nunca para operar sobre el conjunto completo, que permanece distribuido en todo momento; este principio gobierna cada etapa descrita a continuación.

IV-A. Recolección de datos

La recolección se organizó en dos etapas con Python (≥ 3.11), Playwright para automatización web asíncrona y Polars/pandas para estructuración previa a la ingesta.

IV-A1. Extracción de restaurantes: Se construyó un repositorio a partir de búsquedas en Google Maps, iterando sobre un catálogo de 1873 distritos del Perú combinados con categorías gastronómicas, mediante consultas del tipo `<tipo_restaurante>` en el distrito de `<distrito>`, `<provincia>`, `<región>`, `<país>`. Los resultados se exportaron a CSV por región/provincia/distrito y se consolidaron en un archivo maestro. La depuración eliminó duplicados por *Place ID* y registros sin calificación visible, resultando en 39 947 restaurantes. La Tabla I resume las variables conservadas.

IV-A2. Extracción de reseñas: A partir del listado maestro, un segundo orquestador recuperó las reseñas históricas mediante navegación *headless* concurrente, con una bitácora de avance que permite reanudar la extracción ante interrupciones. La concurrencia se calibró empíricamente: ocho procesos paralelos resultaron el mejor compromiso entre tiempo de extracción y volumen recuperado, frente a configuraciones menos paralelas (más lentas) o más agresivas (que degradaban la tasa de recuperación por la respuesta de la plataforma). El corpus resultante reúne cerca de 3.4 millones de reseñas, que tras la deduplicación por identificador se reducen a aproximadamente 2.8 millones de reseñas únicas. La Tabla II resume sus variables.




Figura 1. Arquitectura Lambda del framework, desplegada en Databricks. La capa *batch* procesa el histórico con el patrón medallón (Bronze/Silver/Gold) sobre Delta Lake; la capa de velocidad ingesta las reseñas nuevas vía Kafka y Spark Structured Streaming, descartando duplicados respecto del histórico; ambas rutas convergen en la capa Silver y alimentan las vistas Gold, punto único de consumo para los modelos de aprendizaje y la capa de servicio.




Figura 2. Arquitectura de componentes lógicos: separación de rutas *batch/streaming*, consolidación medallón, vistas Gold y modelamiento con MLlib (implementados). La capa de consumo —tablero y API— corresponde al diseño objetivo previsto, aún no implementado.

IV-B. Procesamiento distribuido

Toda la ingeniería de datos se realizó de forma distribuida sobre Spark, organizada según el patrón medallón. La capa Bronze ingesta el corpus crudo sin alterarlo, conservando su trazabilidad. La capa Silver lo depura: convierte los tipos de dato de manera tolerante a registros corruptos, descarta reseñas

sin calificación o sin fecha válida, elimina duplicados y deriva los atributos que alimentan el análisis posterior —longitud y número de palabras del texto, categoría de calificación y componentes temporales de la fecha—. Para los establecimientos se normalizan las coordenadas y se descartan las inválidas. Es en esta capa donde el histórico y el flujo entrante se unifican

Tabla II
DESCRIPCIÓN DE VARIABLES DEL DATASET DE RESEÑAS

Variable	Descripción
place_id	Llave foránea hacia el id del restaurante
id_review	Identificador único de la reseña
caption	Contenido textual de la reseña
review_date	Fecha de publicación (anclada a la extracción si es relativa)
retrieval_date	Marca temporal del momento de extracción
rating	Calificación numérica (1 a 5)
username	Nombre o seudónimo del usuario
n_review_user	Cantidad histórica de reseñas del usuario

(Sección IV-C). Cabe precisar que el tratamiento textual se limita a normalización, tokenización y eliminación de palabras vacías; no se aplica lematización ni *stemming*.

A diferencia de la versión preliminar —en la que la capa Gold era prácticamente una copia de Silver con una etiqueta de sentimiento— en esta versión la capa Gold materializa tres vistas con propósitos diferenciados, que constituyen la interfaz analítica del sistema: una *tabla maestra* que integra cada reseña con su establecimiento y su sentimiento derivado de la calificación; una vista de *estadísticas por categoría* de restaurante (volumen, calificación media y dispersión, proporción de aprobación); y una vista de *rasgos por usuario* —número de reseñas, calificación media, dispersión y extensión textual, con transformaciones logarítmicas para corregir la fuerte asimetría— que sirve de insumo directo a la segmentación.

IV-C. Ingesta en streaming

La capa de velocidad combina Apache Kafka como canal de mensajería con Spark Structured Streaming como consumidor. Las reseñas se publican particionadas por establecimiento, lo que preserva su orden, y se consumen en micro-lotes con un límite por disparo que actúa como control de flujo ante ráfagas de tráfico.

El elemento distintivo de esta etapa es un filtro anti-duplicados que compara cada reseña entrante contra el histórico antes de incorporarla. En lugar de confiar únicamente en el identificador de la reseña, se calcula una huella criptográfica (*hash* SHA-256) sobre los campos que definen su identidad —establecimiento, identificador, texto, calificación, fecha y autor—, de modo que la comparación es por contenido. Cada micro-lote se depura internamente y luego se contrasta con las huellas ya presentes en el histórico; solo se conservan las reseñas genuinamente nuevas. Así se evita el doble conteo cuando una reseña ya capturada por el procesamiento histórico reaparece en el flujo.

IV-D. Modelamiento distribuido

El aprendizaje no supervisado se ejecuta íntegramente sobre el clúster, sin trasladar el conjunto completo a la memoria del nodo coordinador. La *segmentación de usuarios* parte de los rasgos de actividad por usuario, que se estandarizan y se agrupan con K-Means; el número de segmentos se elige combinando el coeficiente de silueta con el método del codo. El

Tabla III
VOLUMETRÍA DEL CORPUS POR ETAPA DE PROCESAMIENTO

Etapa / entidad	Magnitud
Reseñas crudas (Bronze)	3 431 251
Reseñas únicas (tras dedup.)	2 779 298
Reseñas con texto libre	1 769 378
Establecimientos	39 947
Usuarios distintos	1 204 998
Usuarios con rasgos (segmentación)	~711 000
Calificación media / % 5 estrellas	4.16 / 55.8 %

modelado de tópicos sigue una canalización clásica de minería de texto —tokenización, eliminación de palabras vacías (en español, ampliadas con términos del dominio gastronómico) y ponderación TF-IDF— sobre la que se entrena un modelo LDA que extrae cinco tópicos latentes, interpretados a partir de sus términos dominantes. Los modelos entrenados se persisten para su reaplicación.

El *análisis geoespacial* se resuelve de forma híbrida: la agregación de millones de reseñas por establecimiento ocurre de manera distribuida, y solo el resultado agregado —unas decenas de miles de filas— se cruza con los polígonos administrativos del Perú para producir los mapas. Por privacidad, todos los resultados se reportan de forma agregada y los identificadores de usuario se emplean únicamente como claves técnicas, sin publicar perfiles individuales.

V. RESULTADOS Y DISCUSIÓN

V-A. Perfil y volumetría del corpus

El corpus crudo asciende a 3.43 millones de reseñas sobre 39 947 establecimientos, aportadas por cerca de 1.2 millones de usuarios. La depuración reduce el corpus a unos 2.78 millones de reseñas únicas, de las cuales aproximadamente 1.77 millones (alrededor del 52 %) contienen texto libre; el resto son calificaciones sin comentario. Esta distinción es relevante porque solo las reseñas con texto alimentan el análisis lingüístico, mientras que la totalidad se emplea en los análisis espaciales y reputacionales. La Tabla III resume estas magnitudes por etapa.

Un primer rasgo del corpus es su marcado **sesgo positivo**: la calificación media es de 4.16 sobre 5 y más del 55 % de las reseñas otorgan la máxima puntuación, frente a apenas un 11 % que asignan una o dos estrellas. Este desbalance —común en plataformas de reseñas voluntarias— condiciona la lectura de los resultados posteriores y motiva atender especialmente a la minoría crítica, que suele concentrar la información operativa más accionable.

V-B. Estructura territorial

Los mapas coropléticos (Fig. 3) —generados agregando coordenadas en Spark SQL y cruzando el agregado de locales con polígonos administrativos mediante GeoPandas— evidencian una distribución espacial fuertemente heterogénea, con concentración en Lima Metropolitana y capitales regionales. La vista por departamento confirma el predominio de Lima frente al resto del país, mientras que la vista provincial





Figura 3. Distribución geográfica de reseñas por departamento (izq.) y provincia (der.), en escala logarítmica.



(a) Evolución mensual con tendencia. (b) Engagement por día de la semana.
Figura 4. Dinámica temporal de la participación en la plataforma.

revela núcleos secundarios en las capitales de la costa y la sierra. Este patrón refleja simultáneamente mayor oferta gastronómica, mayor digitalización y mayor propensión a reseñar, por lo que debe leerse como una aproximación a la *visibilidad* gastronómica en Google Maps y no como un censo del sector.

V-C. Dinámica temporal y engagement textual

La distribución temporal agregada (con media móvil de 12 meses) sugiere crecimiento sostenido del volumen de reseñas, mientras que la distribución por día de la semana revela oscilaciones recurrentes en la participación (Fig. 4). Como parte de las fechas proviene de expresiones relativas convertidas a fechas estimadas, estos patrones se interpretan como tendencias descriptivas del corpus.

Un hallazgo más revelador surge al cruzar la extensión del texto con la calificación (Tabla IV, calculada sobre las reseñas con texto). Las reseñas positivas son abrumadoramente mayoritarias pero notablemente breves —en promedio menos de 40 caracteres y unas 7 palabras—, mientras que las negativas, aunque escasas, son más del doble de extensas (unos 92 caracteres y 16 palabras). En otras palabras, quien queda insatisfecho *escribe más*: la minoría crítica aporta proporcionalmente mucha más información cualitativa sobre fallas de servicio que la mayoría satisfecha, lo que la convierte en la fuente más valiosa para el diagnóstico operativo.

V-D. Análisis por categoría de restaurante

La tabla `gold_stats_categoria` permite comparar el desempeño reputacional entre tipos de establecimiento. Filtrando categorías con más de 500 reseñas y ordenando por rating promedio y porcentaje de aprobación se obtiene

Tabla IV
ENGAGEMENT TEXTUAL POR CATEGORÍA DE CALIFICACIÓN

Categoría	Reseñas	Prom. car.	Prom. pal.	Part. (%)
Alta	1 446 040	39.24	6.62	77.94
Media	203 000	40.72	7.23	10.94
Baja	200 328	91.55	16.48	10.80
No clasificada	6 031	60.80	10.20	0.33




Figura 5. Top categorías por rating promedio y porcentaje de aprobación (`gold_stats_categoria`).




Figura 6. Selección de k : coeficiente de silueta (izq.) y método del codo sobre la inercia/WSSSE (der.). El máximo de silueta se alcanza en $k = 7$.




Figura 7. Segmentación de usuarios: volumen por clúster y comportamiento (satisfacción vs. esfuerzo textual).

un ranking robusto (Fig. 5), útil como referencia competitiva por segmento gastronómico.

V-E. Segmentación de usuarios con Spark MLlib

La búsqueda de k combinó el coeficiente de silueta y el método del codo sobre $k \in [2, 9]$ (Fig. 6). Se seleccionó $k = 7$ (silueta 0.6442; inercia/WSSSE 590 652), valor que maximiza la silueta y se ubica en el “codo” de la inercia; $k = 2$ (0.6335) y $k = 3$ (0.6289) también mostraron buena separación, lo que sugiere estructura jerárquica. La Tabla V describe los siete perfiles y su lectura accionable; la Figura 7 muestra su distribución y comportamiento, y la Figura 8 el perfil normalizado de cada métrica por clúster.

Estos perfiles habilitan usos diferenciados: los promotores y validadores (clústeres 5 y 2) sirven para amplificar reputación; los críticos detallistas (clúster 3) concentran información de diagnóstico operativo; y los foodies activos (clúster 4) son candidatos a programas de embajadores. La interpretación es exploratoria y debe validarse antes de automatizar decisiones.

Tabla V
SEGMENTACIÓN DE USUARIOS (KMEANS, SPARK MLlib, $k = 7$, SILUETA 0.6442) Y ACCIONES RECOMENDADAS

Cl.	Perfil	Usuarios	Rating prom.	Lectura accionable
0	Decepcionado silencioso	71 252	2.22	Una sola visita, texto mínimo: campaña de recuperación y encuesta de causa.
1	Recurrente satisfecho	76 797	4.36	<i>Engagement</i> moderado: candidato a programa de fidelización/puntos.
2	Validador masivo	303 101	4.76	Rating casi perfecto con texto mínimo: verificar autenticidad; si es orgánico, explotar como NPS positivo.
3	Crítico detallista	43 033	1.57	Textos largos para quejarse: prioridad operacional, escalar quejas a gestión.
4	Foodie activo	29 980	4.10	Usuario frecuente con criterio: programa de embajadores/influencers.
5	Promotor genuino	147 280	4.84	Recomienda con detalle: incentivar reseñas en Google Maps y redes.
6	Experiencia errática	39 881	3.32	Alta variabilidad (1.88): investigar consistencia del servicio en los locales que frecuenta.




Figura 8. Perfil normalizado de los siete clústeres por métrica (reseñas promedio, rating promedio, variabilidad del rating y palabras promedio).




Figura 9. Dimensiones semánticas de la experiencia gastronómica (LDA, Spark MLlib).

V-F. Tópicos de reseñas con LDA distribuido

El LDA de Spark MLlib sobre el corpus vectorizado identificó cinco tópicos latentes (Tabla VI, Fig. 9). La log-perplejidad se reporta como métrica interna; la interpretación se apoya en los términos dominantes que devuelve `describeTopics`. Los tópicos capturan ejes diferenciados del discurso: quejas operativas asociadas a comida y atención (tópico 0, con términos como *pésima*, *mala*, *falta*), servicio en términos generales (tópico 1, con *bueno*, *servicio*), atención y ambiente positivos (tópico 2, con *excelente*, *acogedor*, *amable*), recomendación familiar (tópico 3, con *mejor*, *familia*, *pizzas*) y sabor de la comida (tópico 4, con *pollo*, *papas*, *rico*). El contraste entre el tópico 0 (negativo) y los tópicos 2 y 4 (positivos) sugiere que el corpus separa razonablemente la insatisfacción operativa de la satisfacción por comida y ambiente. Al no incorporarse una validación externa de coherencia, las etiquetas constituyen lecturas interpretativas del equipo.

Tabla VI
TÓPICOS DETECTADOS POR LDA (SPARK MLlib), TÉRMINOS DOMINANTES E INTERPRETACIÓN

Tóp.	Términos dominantes	Lectura
0	pollo, atención, pésima, mala, son, rico, agradable, sabor, falta	Quejas operativas
1	buen, buena, atención, servicio, platos, estaba, sabor, son	Servicio general
2	excelente, atención, buena, servicio, ambiente, buen, agradable, amable, acogedor	Ambiente positivo
3	mejor, buena, atención, buen, pizzas, buenas, mejores, familia	Recomendación familiar
4	buena, atención, pollo, rico, sabor, agradable, rica, papas	Sabor y comida

V-G. Escalabilidad y rendimiento end-to-end

Para evaluar el comportamiento de la capa de velocidad bajo carga, se diseñó una prueba que emite reseñas en lotes de tamaño creciente (1 000, 2 000, 4 000, ...) y mide dos magnitudes: el *throughput* de ingesta —reseñas por segundo efectivamente persistidas tras el filtro anti-duplicados— y la latencia *end-to-end* desde la publicación de una reseña hasta su disponibilidad para consumo. El límite de mensajes por micro-lote actúa como control de flujo, de modo que el sistema degrada de forma controlada ante ráfagas en lugar de saturarse.

La Figura 10 resume la arquitectura física que soporta esta propiedad: los productores, Kafka, los ejecutores de Spark, las tablas Delta y los servicios de consumo quedan desacoplados, permitiendo escalar el cómputo y la ingesta sin modificar la lógica analítica.

El argumento central es que, al tratarse de un sistema **distribuido**, el rendimiento escala horizontalmente: a mayor volumen, el trabajo se reparte entre los nodos del clúster, por lo que el *throughput* agregado puede aumentarse añadiendo capacidad sin modificar el código. Como evidencia preliminar de esta propiedad, la propia calibración de la extracción mostró un escalamiento positivo al duplicar el paralelismo. La medición formal de la curva de *throughput* frente al tamaño de lote constituye el experimento natural de la capa de velocidad y se acompaña como material reproducible del proyecto.

V-H. Implicancias y limitaciones

Los resultados sugieren que Google Maps puede usarse para aproximar patrones de visibilidad, reputación y experiencia gastronómica, siempre que se reconozcan sus sesgos: la plataforma sobrerrepresenta zonas más digitalizadas y usuarios más




Figura 10. Arquitectura física y componentes tecnológicos: productores, Kafka, Spark Structured Streaming, almacenamiento Delta y clúster de procesamiento/modelamiento (implementados). Los servicios de visualización y exposición (tablero y API REST) representan la capa de consumo prevista en el diseño.

propensos a reseñar. La arquitectura Lambda implementada demuestra que el flujo puede operar tanto sobre el histórico como sobre datos entrantes, sentando una base para monitoreo continuo. Como limitaciones, los modelos son exploratorios y no se reportan pruebas inferenciales ni validación externa de los tópicos; la fecha estimada introduce ruido en el análisis temporal. Además, las figuras y tablas de segmentación (Fig. 6–8, Tabla V) y de tópicos (Fig. 9, Tabla VI) corresponden a la cohorte de modelamiento disponible al momento del entrenamiento —la tabla de rasgos con ~711 000 usuarios y la muestra textual para LDA—; al reentrenar sobre el corpus íntegro de 1.2 millones de usuarios las magnitudes exactas (tamaños de clúster, silueta e inercia, pesos de términos) pueden variar, aunque la estructura cualitativa de los perfiles y de las dimensiones temáticas se mantiene estable.

VI. CONCLUSIONES

Este trabajo diseñó e implementó un *framework* de *Big Data* para transformar reseñas públicas de restaurantes en Google Maps en una base analítica reproducible y escalable sobre el mercado gastronómico peruano visible en la plataforma. La solución articula una arquitectura Lambda con metodología medallón sobre Delta Lake: la capa *batch* depura el histórico de 3.43 millones de reseñas sobre 39 947 establecimientos, mientras que la capa de velocidad incorpora nuevas reseñas mediante Kafka y Spark Structured Streaming, con control de duplicados respecto del histórico.

El procesamiento distribuido sobre Spark en Databricks permitió caracterizar la concentración territorial de la actividad, evidenciar el sesgo positivo de las calificaciones y extraer señales textuales más informativas en reseñas negativas. Además, K-Means identificó siete perfiles de revisores útiles para monitoreo reputacional, diagnóstico operativo y fidelización; y LDA resumió cinco dimensiones temáticas asociadas a servicio, comida, ambiente, recomendación e insatisfacción operativa. En conjunto, el aporte del proyecto es tecnológico y aplicado: integra recolección, procesamiento distribuido, modelamiento no supervisado e ingesta continua en tablas y modelos reutilizables. Como trabajo futuro, se recomienda incorporar fuentes complementarias, validar tópicos con métricas de coherencia y revisión experta, y fortalecer la capa de servicio hacia alertas, recomendación o analítica predictiva en tiempo casi real. Estos hallazgos deben leerse como una aproximación exploratoria al mercado visible en Google Maps, no como un censo del sector gastronómico.

REFERENCIAS

- [1] Redacción El Comercio, «Mincetur: Menos del 1 % de restaurantes formales del país podrá funcionar en

reinicio de actividades,» *El Comercio*, 26 de abr. de 2020, Declaraciones del ministro Edgar Vásquez, MINCETUR. dirección: <https://elcomercio.pe/economia/peru/coronavirus-peru-mincetur-menos-del-1-de-restaurantes-formales-del-pais-podra-funcionar-en-reinicio-de-actividades-apps-de-delivery-covid-19-nndc-noticia/>

- [2] B. Liu, *Sentiment Analysis and Opinion Mining* (Synthesis Lectures on Human Language Technologies). Morgan & Claypool Publishers, 2012. DOI: 10.2200/S00416ED1V01Y201204HLT016
- [3] J. García-Gómez, «Analyzing the growth of the digital footprint in gastronomic SMEs and its correlation with business survival,» *Technological Forecasting and Social Change*, vol. 188, pág. 122 285, 2023.
- [4] P. Silva, R. Costa y N. Pereira, «Evaluating the adoption of Big Data architectures in the hospitality sector: A systematic review,» *IEEE Transactions on Big Data*, vol. 8, n.º 4, págs. 950-964, 2022.
- [5] L. Zhao, S. Wu e Y. Sun, «Building a food industry market observatory using big data architectures,» *Data Science and Management*, vol. 7, n.º 1, págs. 45-56, 2024.
- [6] S. Kim y J. Lee, «Evaluating how spatial distribution affects profitability in the gastronomic sector: An integrated regression model,» *Tourism Management*, vol. 89, pág. 104 462, 2022.
- [7] R. Patel y A. Sharma, «Measuring the impact of Google Maps rating variations on restaurant revenues: A time series analysis,» *International Journal of Hospitality Management*, vol. 112, pág. 103 498, 2023.
- [8] A. Martínez, L. García y M. Rodríguez, «Customer segmentation based on user-generated content: Unsupervised clustering approaches,» *Journal of Business Research*, vol. 170, pág. 114 321, 2024.
- [9] Y. Zhang, H. Li y Z. Wang, «Analyzing online reviews to discover competitive advantages in restaurants: A natural language processing approach,» *Decision Support Systems*, vol. 165, pág. 113 876, 2023.
- [10] D. Torres y E. Díaz, «Linking online complaints with restaurant operational inefficiencies using text mining,» *Computers in Industry*, vol. 145, pág. 103 810, 2023.
- [11] X. Wang, Y. Chen y Q. Liu, «Identifying emerging food trends from online review platforms using topic modeling and entity extraction,» *Information Processing & Management*, vol. 59, n.º 3, pág. 102 875, 2022.
- [12] H. Liu y T. Chen, «Designing hybrid recommendation systems to increase customer lifetime value in res-

taurants.» *Expert Systems with Applications*, vol. 238, pág. 121 743, 2024.

- [13] M. Zaharia, R. S. Xin, P. Wendell et al., «Apache Spark: A Unified Engine for Big Data Processing,» *Communications of the ACM*, vol. 59, n.º 11, págs. 56-65, 2016.
- [14] J. Kreps, N. Narkhede y J. Rao, «Kafka: A Distributed Messaging System for Log Processing,» en *Proc. NetDB Workshop*, 2011, págs. 1-7.
- [15] M. Armbrust, T. Das, L. Sun et al., «Delta Lake: High-Performance ACID Table Storage over Cloud Object Stores,» en *Proc. VLDB Endowment*, vol. 13, 2020, págs. 3411-3424.
- [16] N. Marz y J. Warren, *Big Data: Principles and Best Practices of Scalable Realtime Data Systems*. Manning Publications, 2015.