

Diseño e Implementación de un Framework de Big Data Analytics sobre Reseñas de Restaurantes en el Perú basado en Datos de Google Maps

Fabrizio Marin

*Departamento de Ingeniería
Universidad del Pacífico
Lima, Perú
sf.marinc@alum.up.edu.pe*

Bruno Herrera

*Departamento de Ingeniería
Universidad del Pacífico
Lima, Perú
ba.herrerc@alum.up.edu.pe*

Marx Rojas

*Departamento de Ingeniería
Universidad del Pacífico
Lima, Perú
lm.rojasro@alum.up.edu.pe*

Tadashi Vigo

*Departamento de Ingeniería
Universidad del Pacífico
Lima, Perú
dt.vigop@alum.up.edu.pe*

Mario Auqui

*Departamento de Ingeniería
Universidad del Pacífico
Lima, Perú
mm.auquic@alum.up.edu.pe*

Resumen—Este estudio diseña e implementa un *framework* de analítica de datos para recolectar, organizar y analizar reseñas públicas de restaurantes visibles en Google Maps en el Perú. El flujo integra extracción automatizada con **Playwright**, procesamiento en Python con **pandas** y **Polars**, almacenamiento en formatos tabulares/**Parquet** y análisis exploratorios espaciales, temporales y textuales. El corpus consolidado reúne 39947 restaurantes y aproximadamente 1.8 millones de reseñas. Los resultados muestran una fuerte concentración de actividad en Lima Metropolitana y capitales regionales, diferencias descriptivas en la extensión textual según calificación, segmentos exploratorios de revisores mediante K-Means y tópicos latentes asociados con comida, servicio, precio, ambiente y experiencia general. Los hallazgos deben interpretarse como evidencia del mercado gastronómico observable en Google Maps, no como un censo exhaustivo del sector. El trabajo aporta una base metodológica reutilizable para monitoreo reputacional, inteligencia competitiva y futuras validaciones con fuentes externas.

Index Terms—Big Data Analytics; Google Maps; reseñas en línea; minería de texto; K-Means; LDA; organización medallón; restaurantes peruanos

I. INTRODUCCIÓN

En el Perú la gastronomía es, al mismo tiempo, industria e identidad nacional. Tras el boom gastronómico de la primera década del presente siglo, el país se posicionó entre los destinos culinarios más reconocidos del mundo. Según una nota periodística que recoge declaraciones del MINCETUR, el sector llegó a contar con más de 220,000 establecimientos gastronómicos a nivel nacional y se asociaba con cerca del 11.2 % del PBI [1]. No obstante, este crecimiento sin parangón trajo consigo el desarrollo de un mercado altamente informal, fragmentado y competitivo donde la diferenciación ya no se sostiene únicamente en la propuesta culinaria, sino también en la calidad de la experiencia del cliente.

Medir dicha experiencia de manera sistemática es costoso. Las herramientas convencionales como las encuestas de NPS

transaccional, el mystery shopping y las auditorías de servicio quedan solo al alcance de cadenas respaldadas por importantes líneas presupuestales de las que la microempresa gastronómica carece. Esta última, sin embargo, representa a la mayoría del tejido empresarial del sector.

Este vacío metodológico coexiste, paradójicamente, con una fuente de retroalimentación pública y muy económica: las reseñas en Google Maps. Allí, cualquier comensal puede dejar una valoración en formato de puntaje o texto, visibles para millones de usuarios, convirtiendo a esta plataforma en uno de los repositorios gastronómicos de Contenido Generado por Usuario (UGC, por sus siglas en inglés) más grandes del país. Con todo, esta fuente permanece sistemáticamente desaprovechada, pues la mayoría de los establecimientos no cuenta con procesos para monitorear ni interpretar este flujo continuo de retroalimentación. Los organismos rectores del sector como el MINCETUR tampoco explotan su dimensión agregada para orientar política pública hacia la calidad del servicio.

En ese sentido, si bien a nivel individual, gestionar decenas de reseñas puede resultar viable manualmente, una analítica integral de la industria a nivel nacional rebasa con creces cualquier capacidad convencional. La literatura sobre opinion mining ha demostrado que el texto corto no estructurado de las reseñas en línea contiene señales consistentes sobre atributos de servicio como atención al cliente, tiempo de espera, relación calidad-precio y condiciones del ambiente [2]. Extraer esas señales a escala requiere solvencia para combinar Procesamiento de Lenguaje Natural (NLP) y flujos de procesamiento reproducibles que permitan operar sobre millones de documentos de manera eficiente y reproducible.

Más allá del problema de escala, existe una brecha concreta en la literatura sobre minería de opiniones en plataformas de reseñas, que se concentra predominantemente en contextos

anglosajones con agregadores como Yelp y TripAdvisor, y en corpus en inglés [2]. Por el contrario, estudios integrados, escalables y contextualizados para el sector gastronómico peruano siguen siendo escasos. El presente estudio busca atender esa brecha y sus resultados sugieren que el corpus construido contiene patrones territoriales, temporales y temáticos útiles para producir conocimientos accionables sobre los restaurantes visibles en Google Maps. Por lo tanto, el framework propuesto constituye una herramienta metodológica replicable con aplicaciones directas en la gestión empresarial, la vigilancia competitiva y el diseño de intervenciones públicas orientadas a la excelencia del servicio, siempre que se reconozcan los sesgos de cobertura propios de la plataforma.

El presente trabajo tiene como objetivo general diseñar e implementar un framework de Big Data basado en reseñas de Google Maps para caracterizar la estructura territorial, reputacional y temática del mercado gastronómico peruano observable en la plataforma, y evaluar su utilidad como insumo exploratorio para la toma de decisiones. Para ello, se articulan los siguientes objetivos específicos, que en conjunto conforman un pipeline que integra web scraping, ingeniería de datos y analítica sobre flujos de procesamiento reproducibles:

- Construir un pipeline robusto de recolección, depuración e integración de datos a escala nacional sobre una organización medallón, garantizando trazabilidad y reproducibilidad en cada etapa del proceso.
- Describir la distribución geográfica y temporal de los establecimientos visibles en Google Maps y de la actividad de reseñas, identificando patrones de concentración, visibilidad digital y evolución del comportamiento del consumidor dentro de la plataforma.
- Segmentar a los usuarios/revisores según sus patrones de participación y valoración mediante clustering K-Means, con el fin de identificar perfiles diferenciados de comportamiento evaluativo.
- Extraer los principales tópicos del corpus textual mediante LDA [3], reportando términos dominantes y métricas internas de ajuste para identificar atributos recurrentes de la experiencia gastronómica.
- Sentar una base analítica reutilizable para aplicaciones posteriores, incluyendo sistemas de recomendación, monitoreo continuo del mercado observable y generación de evidencia complementaria para la gestión empresarial y el diseño de políticas públicas sectoriales.

II. REVISIÓN DE LITERATURA

La analítica de macrodatos aplicada a la industria gastronómica ha evolucionado desde enfoques descriptivos basados en reseñas y calificaciones hacia arquitecturas más integradas capaces de transformar el contenido generado por el usuario (UGC, por sus siglas en inglés) en inteligencia de negocio. En el contexto de los restaurantes, el UGC constituye una fuente clave de evidencia sobre la percepción del cliente, la calidad del servicio y el desempeño operativo del establecimiento. En particular, las calificaciones numéricas y las reseñas textuales funcionan como variables proxy de satisfacción, reputación

e incluso de desempeño comercial, lo que ha motivado el uso de técnicas de aprendizaje automático, minería de texto y arquitectura de datos para capturar su valor analítico.

En este marco, diversos estudios han abordado la analítica de restaurantes desde perspectivas complementarias. En el ámbito de la adopción digital y la toma de decisiones, se ha evidenciado que la madurez digital de las empresas gastronómicas y de hospitalidad se relaciona con mejores capacidades de respuesta organizacional y mayor resiliencia operativa [4], [5]. De forma paralela, se han propuesto arquitecturas orientadas al monitoreo continuo del mercado, capaces de integrar múltiples fuentes de información y proporcionar una visión más amplia del entorno competitivo [6]. Estos trabajos son relevantes porque muestran que el valor del dato no se limita al análisis retrospectivo, sino que puede convertirse en soporte para decisiones estratégicas en tiempo casi real.

Otra línea de investigación se ha concentrado en la dimensión espacial y temporal del desempeño restaurantero. Los modelos espaciales han permitido estudiar cómo la aglomeración geográfica, la densidad de competencia y la localización influyen en la rentabilidad y sostenibilidad de los restaurantes [7]. De manera complementaria, los análisis de series temporales han mostrado que las variaciones en la reputación digital, particularmente en plataformas como Google Maps, pueden asociarse con cambios en el flujo de clientes y en los ingresos del negocio [8]. En conjunto, estos estudios confirman que la ubicación y la evolución temporal de la reputación digital son variables esenciales para comprender el comportamiento competitivo del sector.

Asimismo, el análisis del comportamiento del consumidor ha incorporado con mayor fuerza técnicas de procesamiento de lenguaje natural y agrupamiento no supervisado. Algunas investigaciones han utilizado clustering para segmentar clientes a partir de sus patrones de interacción y preferencia, con el fin de apoyar estrategias de marketing más precisas [9]. Otras han aplicado minería de texto sobre reseñas para identificar atributos operativos críticos, como calidad de la comida, rapidez del servicio, limpieza y atención al cliente, transformando comentarios cualitativos en indicadores útiles para la gestión [10], [11]. En la misma línea, el modelado de tópicos ha permitido detectar tendencias emergentes en preferencias gastronómicas y orientar procesos de innovación en menús y propuestas de valor [12]. Finalmente, los sistemas de recomendación híbridos han sido propuestos como mecanismos para personalizar sugerencias de restaurantes y mejorar la retención de usuarios en plataformas digitales [13].

A pesar de estos avances, la literatura presenta limitaciones importantes que justifican la presente investigación. En primer lugar, muchos estudios dependen de conjuntos de datos estáticos, reducidos o restringidos a una sola plataforma, lo que limita su escalabilidad y su capacidad para capturar dinámicas de cambio en el comportamiento del consumidor [4], [9]. En segundo lugar, varias propuestas se concentran en una sola dimensión analítica —por ejemplo, clasificación, segmentación o minería de texto— sin integrar en un mismo flujo las variables espaciales, textuales y reputacionales que caracterizan a los

restaurantes en entornos digitales [7], [12]. En tercer lugar, persisten desafíos técnicos relacionados con la heterogeneidad de las fuentes, la calidad del dato, el sesgo geográfico y la limitada generalización de los modelos cuando se aplican a contextos distintos de aquellos para los que fueron entrenados.

Estas brechas muestran la necesidad de un enfoque más robusto, escalable e integrado que articule la ingesta masiva de UGC, el procesamiento estructurado de datos y la extracción de conocimiento útil para la toma de decisiones. En respuesta a ello, el presente estudio propone un marco de analítica de macrodatos orientado a restaurantes en el contexto peruano, basado en una organización progresiva que separa datos crudos, datos depurados y datos preparados para análisis. Sobre esta base, se integran mecanismos de recolección concurrente, normalización y enriquecimiento de datos provenientes de Google Maps, junto con técnicas de análisis espacial, procesamiento de lenguaje natural y modelado de interacciones usuario-restaurant. De este modo, la investigación busca superar las limitaciones de los enfoques fragmentados previos y construir una base metodológica sólida para el análisis, la segmentación y futuras aplicaciones de recomendación en el sector gastronómico.

III. MATERIALES Y MÉTODOS

La investigación adopta un diseño computacional y exploratorio orientado a construir un repositorio nacional de restaurantes visibles en Google Maps y sus reseñas, procesarlo en formatos eficientes y aplicar análisis descriptivos, espaciales, temporales y de texto. En esta versión, el flujo se describe de acuerdo con lo efectivamente usado en el procesamiento: extracción automatizada, limpieza con Python, almacenamiento en archivos tabulares/Parquet y modelamiento exploratorio con herramientas de análisis de datos y aprendizaje no supervisado.

III-A. Recolección de datos

La recolección se organizó en dos etapas: extracción de restaurantes y extracción de reseñas. Para ambas, se empleó Python (≥ 3.11), con *Playwright* para automatización web asíncrona y librerías como *Polars* y *pandas* para estructuración y preparación de datos.

III-A1. Extracción de restaurantes: Se construyó un repositorio digital de gran escala a partir de búsquedas en Google Maps. Para ampliar la cobertura territorial, el proceso iteró sobre un catálogo de 1873 distritos del Perú y combinó cada distrito con categorías gastronómicas clave, usando consultas del tipo `<tipo_restaurante>` en el distrito de `<distrito>`, `<provincia>`, `<región>`, `<país>`. Los resultados fueron exportados a archivos CSV organizados por región, provincia y distrito, y posteriormente consolidados en un archivo maestro. Debido a que la fuente depende de la cobertura, ranking y disponibilidad pública de Google Maps, el repositorio se interpreta como una aproximación a los establecimientos visibles en la plataforma, no como un censo externo del sector.

La depuración eliminó duplicados mediante el identificador *Place ID*, así como registros que no correspondían a restaurantes o que no contaban con calificación visible. Como resultado,

Tabla I
DESCRIPCIÓN DE VARIABLES DEL DATASET DE RESTAURANTES

Variable	Descripción
id	Identificador único del local (<i>Place ID</i>)
url_place	Enlace canónico de Google Maps
title	Nombre comercial del restaurante
category	Clasificación del establecimiento
address	Dirección física completa
phoneNumber	Número de contacto local
completePhoneNumber	Número de contacto con formato internacional
domain	Dominio web asociado
url	Enlace web externo del establecimiento
coord	Coordenadas espaciales originales (latitud, longitud)
stars	Calificación promedio histórica (1 a 5)
reviews	Volumen total de reseñas recibidas
source_query	Consulta origen utilizada para la extracción

se obtuvo un conjunto final de 39947 restaurantes. La Tabla I resume las principales variables conservadas.

III-A2. Extracción de reseñas: A partir del listado maestro de restaurantes, se desarrolló un segundo proceso de extracción para recuperar reseñas históricas. El orquestador utilizó una instancia de navegador *headless* con contextos concurrentes y una cola de *Place IDs*. Para reducir consumo de recursos, se bloquearon elementos no esenciales de la página, como imágenes y recursos cartográficos, y se mantuvo una bitácora de lugares completados para permitir reanudación ante interrupciones.

La concurrencia se ajustó mediante una prueba operativa sobre 50 restaurantes, con un máximo de 50 reseñas por local. Se compararon configuraciones de 4, 8 y 12 *workers*: 4 *workers* tardaron 237.9 s y recuperaron 1227 reseñas; 8 *workers* tardaron 155.4 s y recuperaron 1251 reseñas; y 12 *workers* tardaron 142.5 s, pero solo recuperaron 724 reseñas. Por ello, se eligieron 8 *workers* como equilibrio entre tiempo de ejecución y volumen recuperado en la prueba. Luego, las reseñas fueron consolidadas, deduplicadas con `id_review` y almacenadas en formato *Parquet*. El conjunto final de reseñas contiene aproximadamente 1.8 millones de registros. La Tabla II resume sus variables principales.

III-B. Procesamiento y organización de datos

El procesamiento se realizó en Python, principalmente con *pandas*, *Polars* y archivos *Parquet*. La organización de datos siguió una lógica medallón como esquema de ordenamiento del flujo: una capa de datos crudos, una capa depurada e integrada y una capa final con variables derivadas para el análisis. En esta versión, dicha organización funciona como estructura reproducible de archivos y notebooks de procesamiento.

La limpieza incluyó tratamiento de textos vacíos, eliminación de duplicados, estandarización de cadenas y conversión de fechas. Las fechas relativas se transformaron usando la fecha de extracción como ancla, por lo que los análisis temporales deben entenderse como aproximaciones descriptivas cuando

Tabla II
DESCRIPCIÓN DE VARIABLES DEL DATASET DE RESEÑAS

Variable	Descripción
place_id	Llave foránea que enlaza con el identificador id del restaurante extraído
id_review	Identificador único de la reseña
caption	Contenido textual redactado en la reseña
relative_date	Fecha relativa de publicación
review_date	Fecha registrada o estimada de publicación, anclada a la fecha de extracción cuando proviene de expresiones relativas
retrieval_date	Marca temporal del momento de extracción
rating	Calificación numérica otorgada (1 a 5)
username	Nombre o seudónimo del usuario
n_review_user	Cantidad histórica de reseñas del usuario
n_photo_user	Cantidad histórica de fotografías del usuario
url_user	Enlace al perfil de Google del usuario
url_source	Enlace directo a la reseña original

la publicación no contaba con una fecha exacta. También se generaron variables derivadas como longitud de caracteres, conteo de palabras y categorías discretas de calificación. Para el procesamiento textual se aplicó tokenización, eliminación de palabras vacías en español y reducción morfológica mediante *stemming*; por tanto, el procedimiento no se presenta como lematización estricta.

Para resguardar la privacidad, los análisis reportados se presentan de forma agregada. Los campos de usuario se utilizaron únicamente como identificadores técnicos para construir métricas de actividad y no se publican perfiles individuales ni enlaces directos a usuarios. En una eventual liberación de datos, estos identificadores deben anonimizarse o excluirse.

III-C. Análisis exploratorio y modelamiento

El análisis espacial se realizó con GeoPandas, cruzando coordenadas de restaurantes con polígonos administrativos del Perú obtenidos de un repositorio público de GitHub. Las coordenadas originales se registraron como latitud y longitud; para el análisis geoespacial se interpretaron como puntos de tipo `Point`, con orden de longitud y latitud y se trabajaron bajo el sistema EPSG 4326 antes del cruce con polígonos administrativos. Las visualizaciones geográficas se usaron para observar concentración de registros, actividad de reseñas y atributos textuales, no para afirmar cobertura censal del mercado gastronómico completo.

El análisis temporal examinó la evolución agregada y semanal de reseñas, así como la matriz temporal de calificaciones. Debido a la presencia de fechas relativas convertidas a fechas estimadas, los patrones temporales se interpretan de manera descriptiva. Además, se comparó el nivel de *engagement* textual por categoría de calificación mediante conteos, longitud promedio de caracteres y palabras.

Finalmente, se aplicaron dos modelos no supervisados con propósito exploratorio. Primero, K-Means segmentó usuarios/revisores a partir de variables agregadas de actividad y valoración: número de reseñas registradas, calificación promedio, dispersión de calificaciones y extensión textual promedio.

Tabla III
RESUMEN DE HALLAZGOS PRINCIPALES

Dimensión	Hallazgo principal
Cobertura de datos	Se consolidaron 39947 restaurantes visibles en Google Maps y aproximadamente 1.8 millones de reseñas.
Patrón espacial	La actividad observada en Google Maps se concentra en Lima Metropolitana y capitales regionales.
Patrón temporal	El volumen de reseñas presenta crecimiento y oscilaciones semanales en la participación.
Segmentación de usuarios	El agrupamiento identifica perfiles diferenciados por intensidad de participación y severidad al calificar.
Estructura temática	El modelamiento de tópicos resume conversaciones asociadas con comida, atención, ambiente, precio y experiencia general.

Antes del agrupamiento, las variables numéricas fueron estandarizadas para reducir diferencias de escala, y la selección del número de grupos se apoyó en diagnósticos visuales de codo y silueta. Segundo, LDA se utilizó para identificar tópicos latentes en el corpus de reseñas. La evaluación se limitó a perplejidad y revisión cualitativa de términos dominantes, por lo que los tópicos deben interpretarse como una síntesis exploratoria del discurso de los usuarios, no como una clasificación semántica validada externamente.

IV. RESULTADOS Y DISCUSIÓN

Esta sección presenta los hallazgos derivados de la construcción del repositorio nacional de restaurantes y reseñas de Google Maps. El análisis debe interpretarse como una aproximación al mercado gastronómico visible en la plataforma, no como un censo externo de todos los restaurantes del país.

IV-A. Panorama general del repositorio construido

La recolección permitió consolidar 39947 restaurantes visibles en Google Maps y aproximadamente 1.8 millones de reseñas. Este volumen confirma la viabilidad operativa del *pipeline* para capturar información pública a gran escala y habilita análisis simultáneos sobre ubicación, reputación, participación de usuarios y contenido textual.

Más allá del volumen, el aporte principal del repositorio es integrar atributos del establecimiento, coordenadas geográficas, calificaciones, actividad de usuarios y texto de reseñas en una misma base analítica. La Tabla III resume los hallazgos agregados más relevantes, mientras que las figuras posteriores muestran los patrones espaciales, temporales y textuales observados.

IV-B. Estructura territorial de los registros y reseñas

Los mapas muestran que los registros georreferenciados y la actividad de reseñas no se distribuyen homogéneamente en el territorio. Las Figuras 1 y 2 evidencian mayor concentración en Lima y otros núcleos urbanos. Este patrón puede reflejar simultáneamente mayor oferta gastronómica, mayor digitalización y mayor propensión de los usuarios a dejar reseñas.





Figura 1. Distribución geográfica de reseñas por región y provincia.



(a) Distribución geográfica a nivel provincial de Lima región. (b) Distribución geográfica a nivel distrital de Lima provincia.

Figura 2. Desagregación espacial de la actividad de reseñas gastronómicas en Lima.

Por ello, los mapas no deben interpretarse como una medida directa de todos los restaurantes existentes, sino como una aproximación a la visibilidad gastronómica dentro de Google Maps. La Figura 3, centrada en palabras por reseña, complementa esta lectura al mostrar diferencias territoriales en intensidad textual.





Figura 3. Detalle espacial de palabras por reseña.



(a) Distribución temporal agregada de reseñas. (b) Distribución temporal semanal de reseñas.

Figura 4. Evolución temporal de la participación en la plataforma.

IV-C. Dinámica temporal y engagement textual

Las Figuras 4 y 5 muestran que la participación en reseñas presenta una dinámica temporal no uniforme. La distribución agregada sugiere crecimiento del volumen de interacciones en el tiempo, mientras que la serie semanal evidencia oscilaciones recurrentes en la publicación de reseñas. Dado que una parte de las fechas proviene de expresiones relativas transformadas a fechas estimadas, estos patrones deben leerse como tendencias descriptivas del corpus y no como una medición temporal exacta de toda la actividad gastronómica del país.

La Tabla IV muestra que las reseñas con calificación baja son menos frecuentes, pero descriptivamente más extensas. Considerando como denominador las 1855399 reseñas clasificadas en la tabla, las reseñas altas concentran 1446040 registros (77.94 %) y promedian 39.24 caracteres y 6.62 palabras; en contraste, las reseñas bajas agrupan 200328 registros (10.80 %) y promedian 91.55 caracteres y 16.48 palabras. Este patrón sugiere que los comentarios negativos pueden contener más información operativa para diagnóstico de servicio, aunque no se reporta aquí una prueba inferencial de diferencia estadística.

IV-D. Segmentación de usuarios y tópicos de reseñas

La Figura 6 muestra una segmentación exploratoria de usuarios mediante K-Means. Los clústeres 0 y 3 agrupan usuarios de baja frecuencia de reseña (1.34 y 1.29 reseñas promedio) con calificaciones altas (4.80 y 4.56). El clúster 2 concentra usuarios poco frecuentes pero críticos, con media

Departamento	2021	2022	2023	2024	2025
AMAZONAS	4.22	4.25	4.12	4.30	4.34
ANCASH	4.16	4.09	4.13	4.17	4.27
APURIMAC	3.98	3.93	3.96	4.02	3.95
AREQUIPA	4.10	4.03	4.02	4.06	4.08
AYACUCHO	3.96	3.99	4.05	4.09	4.17
CAJAMARCA	4.15	4.11	4.11	4.23	4.17
CALLAO	4.17	4.17	4.19	4.21	4.20
CUSCO	4.07	4.06	4.12	4.26	4.43
HUANCAYELICA	3.79	3.74	3.88	4.02	3.82
HUANUCO	4.05	4.01	4.08	4.07	3.98
ICA	4.15	4.08	4.15	4.18	4.28
JUNIN	3.95	3.96	4.03	4.03	3.93
LA LIBERTAD	4.26	4.21	4.25	4.25	4.27
LAMBAYEQUE	4.24	4.23	4.23	4.26	4.24
LIMA	4.23	4.19	4.17	4.20	4.26
LORETO	4.23	4.20	4.23	4.27	4.26
MADRE DE DIOS	3.96	3.96	4.02	4.13	4.11
MOROGUEIA	4.11	3.98	4.03	4.12	3.93
PISCO	3.98	4.11	4.16	4.29	4.37
PURA	4.21	4.16	4.26	4.26	4.24
PUNO	3.67	3.73	3.76	3.93	3.97
SAN MARTIN	4.16	4.21	4.21	4.24	4.29
TACNA	4.10	4.08	4.09	4.18	4.07
TUMBES	4.27	4.17	4.14	4.15	4.15
UCAYALI	4.14	4.11	4.14	4.40	4.28

Figura 5. Matriz temporal de puntajes y comportamiento de calificaciones.




Figura 6. Visualización de clústeres de usuarios obtenidos mediante K-Means.




Figura 7. Visualización de tópicos obtenidos mediante LDA.

cercana a 1.43. En contraste, el clúster 1 reúne usuarios más activos (5.97 reseñas promedio), con calificación media más moderada (3.81) y mayor dispersión (1.22). La lectura de estos perfiles depende de las variables agregadas y estandarizadas descritas en la metodología; por ello, no debe interpretarse como una tipología definitiva de consumidores.

Desde una perspectiva aplicada, estos perfiles sugieren usos diferenciados: los usuarios intensivos pueden ser útiles para seguimiento de reputación, mientras que los usuarios críticos pueden orientar revisiones cualitativas de quejas o fallas de servicio. Esta interpretación es exploratoria y debe validarse con análisis adicionales antes de usarse para decisiones automatizadas.

Por su parte, la Figura 7 y la Tabla V resumen cinco tópicos latentes obtenidos mediante LDA. La perplejidad del modelo fue 2383.15, pero se reporta solo como métrica interna; la interpretación se apoya principalmente en los términos dominantes. Los tópicos se relacionan con comida y servicio general, atención y experiencias mixtas, precio/local/mejora, recomendación familiar y ambiente positivo. Al no incorporarse una validación externa de coherencia semántica, las etiquetas de tópicos deben entenderse como lecturas interpretativas del equipo investigador.

Tabla IV
ENGAGEMENT TEXTUAL POR CATEGORÍA DE CALIFICACIÓN

Categoría	Reseñas	Prom. car.	Prom. pal.	Part. (%)
Alta	1446040	39.24	6.62	77.94
Media	203000	40.72	7.23	10.94
Baja	200328	91.55	16.48	10.80
No clasificada	6031	60.80	10.20	0.33

IV-E. Implicancias y limitaciones

Los resultados sugieren que Google Maps puede utilizarse como fuente útil para aproximar patrones de visibilidad, reputación y experiencia gastronómica, siempre que se reconozcan sus sesgos. La plataforma sobrerrepresenta zonas con mayor digitalización y usuarios más propensos a reseñar, por lo que los resultados no deben leerse como representativos de todo el universo gastronómico peruano.

Aun con esas limitaciones, el repositorio permite tres aplicaciones razonables: mapear zonas con mayor visibilidad digital, identificar segmentos de revisores con distintos comportamientos valorativos y resumir temas recurrentes de las reseñas. Como base empírica inicial, el trabajo deja planteado un flujo reutilizable sobre el cual pueden añadirse validaciones externas, métricas inferenciales y comparaciones formales entre modelos.

V. CONCLUSIÓN

Este estudio demostró la viabilidad operativa de un *framework* de big data para capturar, integrar y analizar información gastronómica de gran escala a partir de datos públicos de Google Maps. La construcción de un repositorio con 39947 restaurantes visibles en la plataforma y aproximadamente 1.8 millones de reseñas permitió identificar patrones territoriales, temporales y temáticos dentro del mercado gastronómico digital observable, así como distinguir perfiles exploratorios de usuarios con comportamientos valorativos diferenciados. En conjunto, los resultados muestran que las reseñas en plataformas digitales no solo reflejan reputación, sino también dinámicas de concentración, participación e interacción útiles para comprender mejor la visibilidad competitiva del sector.

El principal aporte del trabajo consiste en convertir una fuente dispersa de contenido generado por usuarios en una base analítica con valor práctico para la industria gastronómica peruana. Desde esta perspectiva, el *framework* propuesto puede servir como insumo para herramientas de inteligencia competitiva orientadas a identificar zonas de alta visibilidad, monitorear percepciones de servicio, reconocer patrones de insatisfacción y apoyar decisiones empresariales, gremiales o públicas con evidencia complementaria y actualizable. Así, la contribución del estudio no radica solo en el diseño técnico

Tabla V
TÓPICOS DETECTADOS EN LAS RESEÑAS, TÉRMINOS DOMINANTES E INTERPRETACIÓN

Tópico	Términos dominantes	Lectura exploratoria
0	buen, comida, pollo, sabor, servicio, rica, precio, calidad, amable, personal	Comida y servicio general
1	platos, bien, atención, solo, pedí, comida, rico, carta, mala, sabor	Atención y experiencia mixta
2	local, mejorar, pizza, variedad, precios, falta, bien, comer, gustó, pequeño	Local, precio y mejora
3	mejor, delicioso, comida, buenos, recomiendo, deliciosa, familia, ceviche, restaurante, mejores	Recomendación familiar
4	buena, atención, excelente, comida, buena, atención, agradable, ambiente, rico, bueno, buena comida	Ambiente y valoración positiva

de la arquitectura, sino en su capacidad para traducir datos masivos en conocimiento accionable para un sector altamente fragmentado y competitivo.

No obstante, los hallazgos deben interpretarse considerando que la evidencia depende de la cobertura, sesgos y niveles de participación propios de Google Maps, por lo que no representa exhaustivamente a todo el universo de restaurantes ni permite establecer relaciones causales fuertes. Como trabajo futuro, resulta pertinente integrar otras fuentes digitales y operativas, fortalecer la validación empírica de los modelos y avanzar hacia sistemas de monitoreo continuo y analítica predictiva. Bajo ese enfoque, el mayor valor del estudio está en mostrar que la analítica masiva puede pasar de ser un ejercicio descriptivo a convertirse en una infraestructura estratégica para mejorar la comprensión, la gestión y la competitividad de la industria gastronómica peruana.

REFERENCIAS

- [1] Redacción El Comercio, «Mincetur: Menos del 1 % de restaurantes formales del país podrá funcionar en reinicio de actividades,» *El Comercio*, 26 de abr. de 2020, Declaraciones del ministro Edgar Vásquez, MINCETUR. dirección: <https://elcomercio.pe/economia/peru/coronavirus-peru-mincetur-menos-del-1-de-restaurantes-formales-del-pais-podra-funcionar-en-reinicio-de-actividades-apps-de-delivery-covid-19-nndc-noticia/>
- [2] B. Liu, *Sentiment Analysis and Opinion Mining* (Synthesis Lectures on Human Language Technologies). Morgan & Claypool Publishers, 2012. DOI: 10.2200/S00416ED1V01Y201204HLT016
- [3] D. M. Blei, A. Y. Ng y M. I. Jordan, «Latent Dirichlet Allocation,» *Journal of Machine Learning Research*, vol. 3, págs. 993-1022, 2003.
- [4] J. García-Gómez, «Analyzing the growth of the digital footprint in gastronomic SMEs and its correlation with business survival,» *Technological Forecasting and Social Change*, vol. 188, pág. 122 285, 2023.
- [5] P. Silva, R. Costa y N. Pereira, «Evaluating the adoption of Big Data architectures in the hospitality sector: A systematic review,» *IEEE Transactions on Big Data*, vol. 8, n.º 4, págs. 950-964, 2022.
- [6] L. Zhao, S. Wu e Y. Sun, «Building a food industry market observatory using big data architectures,» *Data Science and Management*, vol. 7, n.º 1, págs. 45-56, 2024.
- [7] S. Kim y J. Lee, «Evaluating how spatial distribution affects profitability in the gastronomic sector: An integrated regression model,» *Tourism Management*, vol. 89, pág. 104 462, 2022.
- [8] R. Patel y A. Sharma, «Measuring the impact of Google Maps rating variations on restaurant revenues: A time series analysis,» *International Journal of Hospitality Management*, vol. 112, pág. 103 498, 2023.
- [9] A. Martínez, L. García y M. Rodríguez, «Customer segmentation based on user-generated content: Unsupervised clustering approaches,» *Journal of Business Research*, vol. 170, pág. 114 321, 2024.
- [10] Y. Zhang, H. Li y Z. Wang, «Analyzing online reviews to discover competitive advantages in restaurants: A natural language processing approach,» *Decision Support Systems*, vol. 165, pág. 113 876, 2023.
- [11] D. Torres y E. Díaz, «Linking online complaints with restaurant operational inefficiencies using text mining,» *Computers in Industry*, vol. 145, pág. 103 810, 2023.
- [12] X. Wang, Y. Chen y Q. Liu, «Identifying emerging food trends from online review platforms using topic modeling and entity extraction,» *Information Processing & Management*, vol. 59, n.º 3, pág. 102 875, 2022.
- [13] H. Liu y T. Chen, «Designing hybrid recommendation systems to increase customer lifetime value in restaurants,» *Expert Systems with Applications*, vol. 238, pág. 121 743, 2024.